

Conformer-vMF Method Summary

vMF 超球面表現を用いた音楽表現・学習・生成の定式化

白黒基調・LaTeX 版

概要. 本資料は、MIDI 演奏に含まれる音高、五度圏、音高遷移、拍節位置、和声中心を、vMF 超球面上の方向ベクトルとして扱う Conformer-vMF プロトタイプの手法要約である。学習時には root, chord-like, template, beat/bar 文脈, velocity, timing などマルチタスクに予測し、生成時には和声中心との方向一致度を用いて、音高、強弱、タイミング、音価を制御する。

注記. 本資料は研究プロトタイプの数式整理であり、学習済み重み、著作権のある MIDI、音源ファイルは含まない。また、P²OT は生成必須の部品ではなく、Conformer 表現を prototype 確率として解釈するための補助的な構造レンズとして扱う。

目次

1	目的	3
2	記号一覧	3
3	音高クラスと五度圏座標	3
3.1	五度圏距離	4
4	音高遷移と拍節位置	4
5	vMF 音符方向と和声中心方向	5
6	vMF 分布	5
7	Conformer-vMF の学習	5
7.1	学習 head の整理	6
8	マルチタスク損失	6
9	P ² OT prototype lens	7
10	生成時の音高スコア	7
11	velocity 生成	7
12	timing と duration 生成	8
13	コード・伴奏生成	8

14	MIDI 書き出しと生成アルゴリズム	8
14.1	生成手順	8
15	v6.1 生成制御	9
16	本手法の要点	9

1 目的

本研究では、音楽を単なる離散ラベル列としてではなく、音高・五度圏・遷移・拍節・和声方向を統合した方向データとして表現する。各音符方向を $e_{t,i}$ 、時刻 t の和声中心方向を μ_t とし、両者の方向一致度を用いて、和声認識と生成制御を同じ枠組みで扱う。

Conformer-vMF の主な目的は次の通りである。

- MIDI から得られる音楽的状态を vMF 超球面上の方向ベクトルへ写像する。
- Conformer により時系列文脈を学習し、root, template, beat/bar 文脈などを予測する。
- 生成時には、和声中心との方向一致度を用いて、旋律・伴奏・velocity・timing を制御する。

2 記号一覧

項目	記号	役割
MIDI 音高	$m_{t,i}$	時刻 t の第 i 音の MIDI pitch.
Pitch class	$p_{t,i}$	$m_{t,i} \bmod 12$ で定義される 12 音クラス.
五度圏インデックス	$q_{t,i}$	完全五度写像 $7p_{t,i} \bmod 12$ による位置.
音符特徴ベクトル	$x_{t,i}$	音高円, 五度圏, 遷移, 拍節などを結合した特徴.
音符方向	$e_{t,i}$	$x_{t,i}$ を L2 正規化した超球面上の方向.
和声中心方向	μ_t	同時刻または近接音集合の中心方向.
集中度	κ_t	方向がどれだけ中心へ集中しているかを表す非負値.
方向一致度	$A_{t,i}$	$e_{t,i}^\top \mu_t$. 音と和声中心の近さ.
隠れ状態	h_t	Conformer により得られる時系列文脈表現.
root	r_t	C-B の 12 クラス root ラベル.
template	c_t	maj/min/7th などのコード型または和声テンプレート.
velocity	$v_{t,i}$	MIDI の強弱値.
timing residual	$\delta_{t,i}^{\text{time}}$	グリッド位置からの発音タイミングのずれ.

3 音高クラスと五度圏座標

MIDI 音高 $m_{t,i}$ から pitch class を次のように定義する。

$$p_{t,i} = m_{t,i} \bmod 12. \quad (1)$$

完全五度は半音数で 7 に対応するため、五度圏上の位置を次で定義する。

$$q_{t,i} = 7p_{t,i} \bmod 12. \quad (2)$$

音高円上の角度と五度圏上の角度は次の通りである.

$$\theta_{t,i}^{\text{pc}} = \frac{2\pi}{12} p_{t,i}, \quad \theta_{t,i}^5 = \frac{2\pi}{12} q_{t,i}. \quad (3)$$

それぞれの周期座標は、円周上の 2 次元ベクトルとして与える.

$$u_{t,i}^{\text{pc}} = (\cos \theta_{t,i}^{\text{pc}}, \sin \theta_{t,i}^{\text{pc}}), \quad (4)$$

$$u_{t,i}^5 = (\cos \theta_{t,i}^5, \sin \theta_{t,i}^5). \quad (5)$$

3.1 五度圏距離

2 つの pitch class p_a, p_b に対して、五度圏上の位置を $q_a = 7p_a \bmod 12$, $q_b = 7p_b \bmod 12$ とする. このとき、五度圏距離は 12 点円環上の最短ステップ数として定義できる.

$$d_5(p_a, p_b) = \min(|q_a - q_b|, 12 - |q_a - q_b|). \quad (6)$$

この距離は鍵盤上の半音距離ではなく、和声的な近さを表す. 例えば C と G, C と F は五度圏距離が 1 で近い一方、C と C# は半音では隣接しているが五度圏上では遠い.

4 音高遷移と拍節位置

隣接音の実音高差を次で定義する.

$$\Delta m_{t,i} = m_{t,i} - m_{t-1,i}. \quad (7)$$

pitch class 上の遷移は次で定義する.

$$\Delta p_{t,i} = (p_{t,i} - p_{t-1,i}) \bmod 12. \quad (8)$$

遷移角度と遷移方向ベクトルは次の通りである.

$$\theta_{t,i}^\Delta = \frac{2\pi}{12} \Delta p_{t,i}, \quad (9)$$

$$u_{t,i}^\Delta = (\cos \theta_{t,i}^\Delta, \sin \theta_{t,i}^\Delta). \quad (10)$$

実際の跳躍量は、過度に大きな値を抑えるため、次のように正規化する.

$$d_{t,i} = \tanh\left(\frac{\Delta m_{t,i}}{12}\right). \quad (11)$$

1 拍あたりの tick 数を r , 1 小節の拍数を k , onset tick を $o_{t,i}$, 小節開始 tick を b_t とする. 小節内位置の角度は次で表す.

$$\theta_{t,i}^{\text{bar}} = 2\pi \frac{(o_{t,i} - b_t) \bmod kr}{kr}. \quad (12)$$

拍節位置の周期座標は次で与える.

$$u_{t,i}^{\text{onset}} = (\cos \theta_{t,i}^{\text{bar}}, \sin \theta_{t,i}^{\text{bar}}). \quad (13)$$

5 vMF 音符方向と和声中心方向

音高円座標, 五度圏座標, 遷移座標, 実音高差, 音域成分, 拍節位置を結合し, 音符特徴ベクトルを作る.

$$x_{t,i} = [u_{t,i}^{\text{pc}}, u_{t,i}^5, u_{t,i}^{\Delta}, d_{t,i}, h(m_{t,i}), u_{t,i}^{\text{onset}}, \phi_t^{\text{beat}}, \phi_t^{\text{bar}}]. \quad (14)$$

このベクトルを L2 正規化し, 超球面上の音符方向を得る.

$$e_{t,i} = \frac{x_{t,i}}{\|x_{t,i}\|_2 + \epsilon}. \quad (15)$$

同時刻または近接時刻の音集合を C_t とし, 各音の重みを $w_{t,i}$ とする. 和声中心方向は次で定義する.

$$\mu_t = \frac{\sum_{i \in C_t} w_{t,i} e_{t,i}}{\|\sum_{i \in C_t} w_{t,i} e_{t,i}\|_2 + \epsilon}. \quad (16)$$

各音符方向と和声中心方向の一致度を内積で定義する.

$$A_{t,i} = e_{t,i}^\top \mu_t. \quad (17)$$

$A_{t,i}$ が大きいほど, その音は現在の和声中心に近い. 生成時には, この値を velocity 補正や chord-tone 優先に利用する.

6 vMF 分布

単位超球面上の方向データに対して, vMF 分布は次で表される.

$$p(e \mid \mu, \kappa) = C_D(\kappa) \exp(\kappa \mu^\top e). \quad (18)$$

ここで, μ は平均方向, κ は集中度, $C_D(\kappa)$ は次元 D に依存する正規化定数である. κ が大きいほど方向は μ の近くに集中し, κ が小さいほど分布は広がる.

7 Conformer-vMF の学習

Conformer-vMF は, 時系列入力から隠れ状態 h_t を得る.

$$h_{1:T} = \text{Conformer}(e_{1:T}, \mu_{1:T}, \kappa_{1:T}, \text{context}). \quad (19)$$

各 head は root, chord-like, template, triad, seventh, beat, bar, onset, velocity, timingなどを予測する. 代表的な予測式は次の通りである.

$$\hat{r}_t = \text{softmax}(W_r h_t + b_r), \quad (20)$$

$$\hat{y}_t^{\text{cl}} = \sigma(W_{\text{cl}} h_t + b_{\text{cl}}), \quad (21)$$

$$\hat{c}_t = \text{softmax}(W_c h_t + b_c), \quad (22)$$

$$\hat{\mu}_t = \frac{W_\mu h_t + b_\mu}{\|W_\mu h_t + b_\mu\|_2 + \epsilon}, \quad (23)$$

$$\hat{\kappa}_t = \text{softplus}(W_\kappa h_t + b_\kappa). \quad (24)$$

7.1 学習 head の整理

予測対象	代表的な出力	主な損失
vMF 方向	$\hat{\mu}_t$	cosine loss / MSE
集中度	$\hat{\kappa}_t$	MAE / MSE / vMF NLL
root	$\hat{r}_t$	cross entropy
chord-like	$\hat{y}_t^{\text{cl}}$	binary cross entropy
chord template	$\hat{c}_t$	cross entropy
triad / seventh	多クラスまたは 2 値	cross entropy / BCE
beat / bar context	多クラスまたは multi-label	CE / weighted BCE
onset	2 値	BCE
velocity	連続値	MAE / MSE / Smooth L1
timing residual	連続値	MAE / Smooth L1
duration	連続値または分類	MAE / CE
melody / bass flag	2 値	BCE
P ² OT prototype	γ_t	entropy regularization / CE 補助

8 マルチタスク損失

全体の学習損失は、方向回帰、集中度回帰、分類損失、連続値回帰を重み付きで足し合わせる。

$$\begin{aligned} \mathcal{L} = & \lambda_{\mu} \mathcal{L}_{\mu} + \lambda_{\kappa} \mathcal{L}_{\kappa} + \lambda_{\text{root}} \mathcal{L}_{\text{root}} + \lambda_{\text{cl}} \mathcal{L}_{\text{cl}} + \lambda_{\text{temp}} \mathcal{L}_{\text{temp}} \\ & + \lambda_{\text{beat}} \mathcal{L}_{\text{beat}} + \lambda_{\text{bar}} \mathcal{L}_{\text{bar}} + \lambda_{\text{vel}} \mathcal{L}_{\text{vel}} + \lambda_{\text{time}} \mathcal{L}_{\text{time}}. \end{aligned} \quad (25)$$

方向損失は、予測方向と正解方向の cosine loss として定義できる。

$$\mathcal{L}_{\mu} = 1 - \hat{\mu}_t^{\top} \mu_t. \quad (26)$$

root や template などの多クラス分類には cross entropy を用いる。

$$\mathcal{L}_{\text{root}} = - \sum_{c=1}^{12} y_{t,c}^{\text{root}} \log \hat{y}_{t,c}^{\text{root}}. \quad (27)$$

chord-like や onset などの 2 値分類には binary cross entropy を用いる。

$$\mathcal{L}_{\text{cl}} = -y_t^{\text{cl}} \log \hat{y}_t^{\text{cl}} - (1 - y_t^{\text{cl}}) \log(1 - \hat{y}_t^{\text{cl}}). \quad (28)$$

velocity や timing residual などの連続値には、MAE, MSE, Smooth L1 などを用いる。

$$\mathcal{L}_{\text{vel}} = |v_{t,i} - \hat{v}_{t,i}|. \quad (29)$$

9 P²OT prototype lens

P²OT は生成に必須の部品ではなく、Conformer 表現を prototype 確率として読むための補助的な構造レンズとして扱う。prototype を z_k 、隠れ状態を h_t とすると、距離に基づく prototype 分布を次のように置く。

$$\gamma_{t,k} = \frac{\exp(-d(h_t, z_k)/\tau)}{\sum_{j=1}^K \exp(-d(h_t, z_j)/\tau)}. \quad (30)$$

ここで、 K は prototype 数、 τ は温度である。 γ_t は確率単体上の分布として解釈できる。

10 生成時の音高スコア

生成時には、候補音 m に対して、和声一致度、コード構成音らしさ、反復抑制、大跳躍抑制、同方向連続抑制を組み合わせて score を作る。

$$S_t(m) = \beta_A A_t(m) + \beta_{\text{tone}} T_t(m) - \alpha_{\text{rep}} R_t(m) - \alpha_{\text{leap}} L_t(m) - \alpha_{\text{same}} D_t(m). \quad (31)$$

各項の意味は次の通りである。

項	意味
$A_t(m)$	候補音と和声中心方向の一致度。
$T_t(m)$	予測 root/template に基づくコード構成音らしさ。
$R_t(m)$	同音反復へのペナルティ。
$L_t(m)$	大跳躍へのペナルティ。
$D_t(m)$	同方向に進み続ける動きへのペナルティ。

候補音のサンプリング確率は、温度付き softmax で与える。

$$P_t(m) = \frac{\exp(S_t(m)/\tau_{\text{mel}})}{\sum_{m'} \exp(S_t(m')/\tau_{\text{mel}})}. \quad (32)$$

温度 τ_{mel} が小さいほど生成は決定的になり、大きいほど多様性が増す。

11 velocity 生成

生成 velocity は、基本 velocity、和声一致度、メロディ補正、ベース補正、ランダム揺らぎを足し合わせて決定する。

$$v_{t,i} = \text{clip}(v_0 + \beta_A A_{t,i} + \beta_{\text{mel}} M_{t,i} + \beta_{\text{bass}} B_{t,i} + \epsilon_{t,i}^v, 1, 127). \quad (33)$$

ここで、 $M_{t,i}$ はメロディ音フラグ、 $B_{t,i}$ はベース音フラグ、 $\epsilon_{t,i}^v$ は自然な強弱の揺らぎである。例えば、揺らぎは次のように置ける。

$$\epsilon_{t,i}^v \sim \mathcal{N}(0, \sigma_v^2). \quad (34)$$

12 timing と duration 生成

発音タイミングは、グリッド位置に timing residual と揺らぎを加えて決定する.

$$\tilde{o}_{t,i} = o_{t,i}^{\text{grid}} + \hat{\delta}_{t,i}^{\text{time}} + \epsilon_{t,i}^{\text{time}}. \quad (35)$$

必要に応じて、量子化幅 g により onset を丸める.

$$o_{t,i}^{\text{out}} = g \left\lfloor \frac{\tilde{o}_{t,i}}{g} + \frac{1}{2} \right\rfloor. \quad (36)$$

音価は、予測 duration またはリズム template から得て、自然な範囲へ制限する.

$$\ell_{t,i} = \text{clip} \left(\hat{\ell}_{t,i}, \ell_{\min}, \ell_{\max} \right). \quad (37)$$

offset は次で与える.

$$f_{t,i} = o_{t,i}^{\text{out}} + \ell_{t,i}. \quad (38)$$

13 コード・伴奏生成

予測された root と template から、コード構成音集合を定義する.

$$\mathcal{C}_t = \{ \hat{r}_t + l \pmod{12} \mid l \in \mathcal{I}(\hat{c}_t) \}. \quad (39)$$

ここで、 $\mathcal{I}(\hat{c}_t)$ は予測 template に対応する root-normalized interval 集合である. 例えば, major triad は次のように表せる.

$$\mathcal{I}(\text{maj}) = \{0, 4, 7\}. \quad (40)$$

コード音は伴奏音域に、ベース音は低音域に配置する.

$$m_{t,j}^{\text{chord}} = 12O_{\text{chord}} + c_{t,j}, \quad c_{t,j} \in \mathcal{C}_t, \quad (41)$$

$$m_t^{\text{bass}} = 12O_{\text{bass}} + \hat{r}_t. \quad (42)$$

14 MIDI 書き出しと生成アルゴリズム

最後に、生成された音符を pitch, onset, offset, velocity からなる MIDI イベントとして書き出す.

$$\text{MIDI} = \text{Render} \left(m_{t,i}, o_{t,i}^{\text{out}}, f_{t,i}, v_{t,i} \right). \quad (43)$$

14.1 生成手順

1. root, chord-like 確率, template, beat/bar 文脈を予測または設定する.
2. 和声方向 μ_t と集中度 κ_t を推定する.
3. 許容音域内の候補音 m を列挙する.
4. 各候補音を vMF 方向 $e(m)$ へ変換する.
5. 和声一致度 $A_t(m)$ と音高スコア $S_t(m)$ を計算する.
6. 温度付き softmax により候補音を選択またはサンプリングする.
7. velocity, timing, duration を計算し, MIDI イベントとして書き出す.

15 v6.1 生成制御

v6.1 の生成設定では、よくある失敗を抑えるため、次の制御を導入した。

制御	目的
start mask	最初以外の start 連続を禁止する。
repeat penalty	同音反復による張り付きを抑制する。
leap penalty	不自然な大跳躍を抑制する。
same-direction penalty	上行または下行に進み続ける単調さを抑制する。
chord-tone preference	和声的に安定したコード構成音を優先する。

これらの制御は独立した neural head ではなく、生成時の sampling score に加える制約である。

16 本手法の要点

Conformer-vMF では、音高やコードを単なる離散ラベルとして扱うだけでなく、五度圏、遷移、拍節、和声中心を方向として統合する。これにより、各音が現在の和声中心にどれだけ近いかを $A_{t,i}$ として定量化できる。生成時には、この方向一致度を用いて、和声的に自然な音を強め、大跳躍や同音反復を抑えた旋律・伴奏生成を行う。

本資料は GitHub 掲載用の Method Summary を白黒 LaTeX 版として整理したものである。